Introducción a Ingeniería en Ciencia de Datos — Apuntes de estudio

Presentación

Estos apuntes llevan los datos desde su estado crudo hasta una descripción útil: cómo organizarlos en pandas, resumirlos con tablas y estadísticos, representarlos en gráficos y manejarlos de forma legal y ordenada.

Mapa del contenido

1. Fundamentos: DataFrame, estadística descriptiva y tipos de variables.
2. pandas esencial: agrupar, combinar y convertir tipos de datos.
3. Tablas de frecuencia (simples y por intervalos).
4. Medidas de tendencia central.
5. Medidas de dispersión.
6. Visualización de datos.
7. Datos personales y ley colombiana (Ley 1581 de 2012).
8. Arquitecturas de almacenamiento (Data Lake, Data Warehouse, Data Mart).
9. Caso de estudio: recomendaciones de YouTube.
10. Lectura complementaria: *The Thinking Game*.
11. Repaso final: fórmulas, errores frecuentes y autoevaluación.

Cómo estudiar con estos apuntes

- Calcula a mano cada ejemplo numérico antes de pasar al código; así entiendes qué hace la función.
- Ejecuta los fragmentos de pandas con un DataFrame propio y cambia los parámetros para ver qué ocurre.
- Cierra cada bloque con las preguntas de la sección 11.

Notación usada

Símbolo	Significado
n	Número total de datos
xi	Valor i-ésimo de la variable (o marca de clase, si hay intervalos)

Símbolo	Significado
fi	Frecuencia absoluta: cuántas veces aparece xi
hi	Frecuencia relativa: fi / n
Fi	Frecuencia absoluta acumulada
Hi	Frecuencia relativa acumulada
$\bar{x}$	Media aritmética
Me	Mediana
Mo	Moda
Q1, Q2, Q3	Cuartiles (Q2 = mediana)
IQR	Rango intercuartil: Q3 − Q1

1. Fundamentos

Todo análisis empieza igual: se organizan los datos en una tabla (DataFrame), se describen con estadística descriptiva y se identifica qué tipo de variable es cada columna, porque de eso depende qué resumen es válido.

1.1 DataFrame

Un **DataFrame** es una estructura de datos organizada en **filas y columnas con etiquetas**, como una hoja de cálculo. En pandas (la librería de Python para análisis de datos), cada fila representa una observación (un individuo o registro) y cada columna representa una variable.

1.2 Estadística descriptiva

La **estadística descriptiva** es la rama de la estadística que recopila, organiza, resume y presenta datos para describir sus características principales, **sin hacer inferencias** sobre una población más amplia (eso corresponde a la estadística inferencial).

Su objetivo es transformar datos crudos en información útil: mostrar tendencias, patrones y variabilidad dentro de la muestra o población estudiada. Para lograrlo usa tres herramientas:

- **Medidas numéricas**: promedio, mediana, desviación estándar, etc.
- **Tablas**: por ejemplo, las tablas de frecuencia.
- **Gráficos**: barras, histogramas, diagramas de caja, etc.

1.3 Población, muestra y variable estadística

- **Población**: el conjunto completo de individuos que se quiere estudiar.
- **Muestra**: un subconjunto de la población.
- **Variable estadística**: cualquier característica observable que puede tomar distintos valores en los individuos de una población (edad, estatura, mano dominante, nivel de Python).

1.4 Tipos de variables

El tipo de variable determina cómo se resume y qué gráfico se usa. Se dividen en dos grandes familias:

Familia	Tipo	Qué representa	Ejemplos	Resumen adecuado
Categórica (cualitativa)	Nominal	Categorías sin orden	Mano dominante, tipo de transporte, nacionalidad	Frecuencias, moda
Categórica (cualitativa)	Ordinal	Categorías con un orden lógico	Nivel de Python (Ninguno < Básico < Intermedio < Avanzado)	Frecuencias, frecuencias acumuladas, mediana, moda
Cuantitativa (numérica)	Discreta	Conteos (valores enteros)	Número de mascotas, goles, asistencias	Tendencia central, dispersión, frecuencias
Cuantitativa (numérica)	Continua	Mediciones en un rango continuo	Estatura, peso, horas de estudio	Tendencia central, dispersión, intervalos

Para los datos numéricos se estudian tres aspectos:

- **Tendencia central**: dónde está el "medio" de los datos (sección 4).
- **Dispersión**: qué tan concentrados o esparcidos están los valores (sección 5).
- **Relación entre dos variables**: análisis bivariable, que va más allá de estos apuntes.

El **análisis univariable** describe una sola variable (una columna: edad, salario, estatura, número de mascotas) mediante números representativos. Su primer bloque son las tablas de frecuencia (sección 3), que responden: ¿cuántos casos hay de cada valor?, ¿qué porcentaje representa cada uno? y ¿cómo se acumula la distribución hasta cierto punto?

2. pandas esencial

Cuatro operaciones cubren casi todo el trabajo previo al análisis: agrupar filas para resumirlas, combinar tablas, convertir el tipo de las columnas y definir categorías con orden. Los ejemplos usan datos de jugadores de fútbol (`df`, `df_players`, `df_stints`, `df_countries`).

2.1 Agrupar por columna (`groupby`)

`groupby` divide el DataFrame en grupos según una o varias columnas y permite aplicar una función de resumen a cada grupo (`sum`, `mean`, `count`, etc.).

```
import pandas as pd

# 1. Agrupar por dos columnas
grupos_mixtos = df.groupby(["nationality", "dominant_foot"])

# 2. Resumir cada grupo (agregación con nombre)
resumen_ofensivo = grupos_mixtos.agg(
    total_asistencias=("assists", "sum"),
    total_goles=("goals", "sum"),
).reset_index()          # convierte los índices del grupo en columnas
normales

# 3. Ordenar por varias columnas con sentido distinto
ordenamiento_compuesto = resumen_ofensivo.sort_values(
    by=["nationality", "total_goles"],
    ascending=[True, False],   # nacionalidad A→Z, goles de mayor a menor
)
```

El patrón es siempre el mismo: **agrupar → agregar → (reiniciar índice) → ordenar**.

2.2 Combinar DataFrames (`merge`)

`pd.merge` une dos tablas que comparten una llave (por ejemplo, un identificador), de forma similar a un `JOIN` de SQL. El ejemplo encadena cinco pasos para obtener los jugadores activos de un club junto con su país.

```
# Paso 1: unir jugadores con su historial (misma llave en ambas tablas:
"player_id")
jugadores_con_historial = pd.merge(
    df_players,
    df_stints,
    on="player_id",
    how="inner",
```

```
)

# Paso 2: unir con países (la llave tiene nombres distintos en cada tabla)
resultado_combinacion = pd.merge(
    jugadores_con_historial,
    df_countries,
    left_on="represented_country_id",
    right_on="country_id",
    how="inner",
)

# Paso 3: filtrar filas (cada condición entre paréntesis, unidas con &)
resultado_activos_pb = resultado_combinacion.loc[
    (resultado_combinacion["club_id"] == "PB001") &
    (resultado_combinacion["is_current_club"] == True),
    :,
]

# Paso 4: renombrar columnas
resultado_activos_pb = resultado_activos_pb.rename(columns={
    "full_name": "nombre_jugador",
    "country_name": "nacionalidad",
})

# Paso 5: quedarse solo con las columnas de interés
resultado_activos_pb[["nombre_jugador", "nacionalidad"]]
```

- **`on`** se usa cuando la llave tiene **el mismo nombre en ambos DataFrames**.
- **`left_on`** / **`right_on`** se usan cuando la llave tiene **nombres distintos** en cada tabla.
- **`how`** define qué filas se conservan:

how	Resultado
`inner`	Solo las filas cuya llave existe en ambas tablas
`left`	Todas las filas de la tabla izquierda; las que no tienen pareja quedan con `NaN`
`right`	Todas las filas de la tabla derecha
`outer`	Todas las filas de ambas tablas

2.3 Transformar el tipo de una variable

Una columna se carga a menudo con un tipo inadecuado (por ejemplo, números como texto). Convertirla al tipo correcto es indispensable para poder calcular, ordenar y comparar. Para revisar el tipo actual se usa `df["columna"].dtype`.

a) A categoría (`category`): para variables con pocos valores repetidos (nacionalidad, mano dominante). Ahorra memoria y deja claro que la variable es categórica.

```
print(f"Tipo original: {df['nationality'].dtype}")
df["nationality"] = df["nationality"].astype("category")
print(f"Tipo transformado: {df['nationality'].dtype}")
```

b) A numérico (`int`, `float`): si una columna numérica se cargó como `object` (texto) por valores no numéricos o mal formateados, se usa `pd.to_numeric`, que es más robusta que `astype` porque maneja errores.

```
# errors="coerce" convierte lo que no se puede convertir en NaN
df["appearances"] = pd.to_numeric(df["appearances"], errors="coerce")

# Después, decidir qué hacer con los NaN (ver sección 2.5), por ejemplo:
# df["appearances"] = df["appearances"].fillna(0).astype(int)
```

c) A fecha y hora (`datetime`): las fechas suelen cargarse como texto. Al convertirlas se pueden extraer año, mes y día, y calcular diferencias de tiempo.

```
df_2 = pd.read_csv("pb_players(in).csv")
df_2["birth_date"] = pd.to_datetime(df_2["birth_date"], errors="coerce")

df_2["birth_date"].dt.year      # extrae el año
```

d) A booleano (`bool`): una comparación genera directamente una columna de verdadero/falso.

```
df["high_assists"] = df["assists"] > 5     # True si tiene más de 5
asistencias
df[["assists", "high_assists"]].head()
```

2.4 Categorías con orden (`Categorical`)

Cuando las categorías tienen una jerarquía (por ejemplo, un nivel de conocimiento), se define explícitamente el orden:

```
nivel_python_orden = ["Ninguno", "Básico", "Intermedio", "Avanzado"]
df["Python"] = pd.Categorical(
    df["Python"],
    categories=nivel_python_orden,
    ordered=True,
)
```

- **`ordered=True`**: indica a pandas que las categorías tienen un **orden lógico definido** (no son solo etiquetas). Se respeta el orden que declaraste y se permiten comparaciones con `<` y `>`; además, `sort_values` ordena según esa jerarquía (Ninguno → Avanzado).
- **`ordered=False`** (por defecto): solo se permiten `==` y `!=`. Comparar con `<` o `>` produce un error, y el ordenamiento sigue el orden de las categorías (alfabético por defecto), no una jerarquía lógica.

2.5 Buenas prácticas

`pd.cut()` frente a `pd.qcut()`. `pd.cut()` crea intervalos de **ancho igual** (o con los límites que tú definas): es lo ideal cuando quieres rangos predefinidos. `pd.qcut()` crea intervalos con **aproximadamente el mismo número de observaciones** (cuartiles, quintiles, etc.), aunque los anchos varíen. Elige `qcut` cuando importe más el reparto de datos por intervalo que el tamaño del intervalo.

Funciones `lambda`. Una `lambda` es una función pequeña y desechable de una sola línea, útil para pasarla como argumento (por ejemplo, a `apply`). Si la lógica se complica o se reutiliza en varios lugares, es mejor una función definida con `def`: se lee mejor y es más fácil de depurar.

Operaciones que devuelven copias. La mayoría de los métodos de pandas **no modifican el objeto original: devuelven un DataFrame o una Serie nuevos**, por eso hay que reasignar el resultado (`df = df.sort_values(...)`). Existe el argumento `inplace=True`, pero hoy se desaconseja: no suele ahorrar memoria y genera confusión.

Nombres descriptivos. Usa nombres de columnas y variables que expliquen su contenido (`intervalo`, `fi`, `total_goles`). Tu código será más fácil de entender para ti y para otros.

Valores faltantes (`NaN`). Cuando usas `errors="coerce"` (en `pd.to_numeric` o `pd.to_datetime`), lo que no se puede convertir pasa a `NaN` (o `NaT` en fechas). Después debes decidir qué hacer con esos valores:

- Eliminarlos con `dropna()`.
- Rellenarlos con `fillna()` usando un valor como 0, la media o la mediana, según el contexto.

3. Tablas de frecuencia

Una tabla de frecuencia es el primer paso del análisis univariable: cuenta cuántas veces aparece cada valor de una variable y qué proporción del total representa.

3.1 Qué se calcula

Símbolo	Nombre	Cálculo	Qué responde
fi	Frecuencia absoluta	Conteo de veces que aparece xi	¿Cuántos casos hay?
hi	Frecuencia relativa	fi / n	¿Qué proporción del total es?
hi %	Frecuencia relativa porcentual	hi × 100	¿Qué porcentaje es?
Fi	Frecuencia absoluta acumulada	Suma de las fi hasta xi	¿Cuántos casos hay hasta este valor?
Hi	Frecuencia relativa acumulada	Suma de las hi hasta xi	¿Qué proporción hay hasta este valor?

Importante: las frecuencias acumuladas solo tienen sentido cuando los valores xi tienen orden, es decir, en variables cuantitativas y cualitativas ordinales.

3.2 Tabla de frecuencia simple

Organiza una variable registrando **los valores distintos y cuántas veces aparece cada uno**. Es la tabla adecuada para variables categóricas y para variables discretas con pocos valores distintos.

Ejemplo. En un grupo de n = 20 estudiantes se registra la mano dominante:

Mano (xi)	fi	hi	hi %
Derecha	17	17 / 20 = 0.85	85 %
Izquierda	3	3 / 20 = 0.15	15 %
Total	**20**	**1.00**	**100 %**

Interpretación: el 85 % de los estudiantes es diestro.

```
n = len(df)

tabla_de_frecuencia = (
    df.groupby("Mano")
      .agg(fi=("id", "count"))   # cuenta cuántos registros hay por categoría
      .reset_index()
      .sort_values(by="Mano")
)

tabla_de_frecuencia["hi"] = tabla_de_frecuencia["fi"] / n
tabla_de_frecuencia["hi%"] = tabla_de_frecuencia["hi"] * 100

tabla_de_frecuencia = tabla_de_frecuencia.rename(columns={
    "Mano": "Mano (xi)",
    "fi": "Frecuencia absoluta (fi)",
    "hi": "Frecuencia relativa (hi)",
    "hi%": "Frecuencia relativa porcentual (hi) %",
})
```

3.3 Tabla de frecuencia por intervalos

Cuando una variable continua (o discreta con muchos valores distintos) tiene un rango amplio, conviene **agrupar los datos en intervalos**: así se ve la forma general de la distribución con más claridad. Un **intervalo** es un rango de valores usado para agrupar datos cuantitativos.

La tabla por intervalos registra cuántas observaciones caen en cada clase y puede incluir frecuencias relativas, acumuladas y la **marca de clase**, que es el punto medio del intervalo y lo representa en los cálculos:

```
x_i = \frac{L_{inferior} + L_{superior}}{2}
```

Como guía para elegir el número de intervalos se suele usar la regla de Sturges: k ≈ 1 + 3.322 · log10(n). Es una orientación, no una obligación.

```
n = len(df)

# 1. Asignar cada dato a un intervalo
df["intervalo"] = pd.cut(
    df["Horas/día"],
    bins=[1, 2, 3, 4, 5, 6, 7],   # límites de los intervalos
    right=False,                  # intervalos cerrados a la izquierda: [a,
b)
)
```

```
# 2. Contar datos por intervalo (fi)
tabla_de_frecuencia = (
    df.groupby("intervalo", observed=False)   # observed=False conserva
intervalos vacíos
      .agg(fi=("id", "count"))
      .reset_index()
      .sort_values("intervalo")
)

# 3. Marca de clase y demás frecuencias
tabla_de_frecuencia["xi"] = (
    tabla_de_frecuencia["intervalo"]
    .apply(lambda x: (x.left + x.right) / 2)   # lambda: punto medio de cada
intervalo
    .astype(float)
)
tabla_de_frecuencia["Fi"] = tabla_de_frecuencia["fi"].cumsum()
tabla_de_frecuencia["hi"] = tabla_de_frecuencia["fi"] / n
tabla_de_frecuencia["hi%"] = tabla_de_frecuencia["hi"] * 100
tabla_de_frecuencia["Hi"] = tabla_de_frecuencia["hi"].cumsum()

# 4. Ordenar y renombrar columnas
tabla_de_frecuencia = tabla_de_frecuencia[["intervalo", "xi", "fi", "Fi",
"hi", "hi%", "Hi"]]
tabla_de_frecuencia = tabla_de_frecuencia.rename(columns={
    "intervalo": "Intervalo",
    "xi": "Marca (xi)",
    "fi": "Frecuencia absoluta (fi)",
    "Fi": "Frecuencia absoluta acumulada (Fi)",
    "hi": "Frecuencia relativa (hi)",
    "hi%": "Frecuencia relativa porcentual (hi) %",
    "Hi": "Frecuencia relativa acumulada (Hi)",
})
```

Cómo se interpretan los límites de `pd.cut`:

- `right=True` (valor por defecto): intervalos (a, b], abiertos a la izquierda. Con `include_lowest=True`, el valor mínimo entra en el primer intervalo aunque coincida con su límite inferior.
- `right=False`: intervalos [a, b), cerrados a la izquierda. El último límite queda **excluido**, así que debe ser mayor que el valor máximo de los datos; de lo contrario ese dato queda como `NaN`.

Resultado ilustrativo (30 estudiantes, variable Horas/día):

Intervalo	xi	fi	Fi	hi	hi %	Hi
[1, 2)	1.5	3	3	0.100	10.0	0.100
[2, 3)	2.5	7	10	0.233	23.3	0.333
[3, 4)	3.5	6	16	0.200	20.0	0.533
[4, 5)	4.5	4	20	0.133	13.3	0.667
[5, 6)	5.5	4	24	0.133	13.3	0.800
[6, 7)	6.5	6	30	0.200	20.0	1.000

Lectura: 10 de los 30 estudiantes (33.3 %) dedican menos de 3 horas diarias (Fi = 10, Hi = 0.333 en el intervalo [2, 3)). Los datos de este ejemplo son ilustrativos.

4. Medidas de tendencia central

Las medidas de tendencia central resumen en un solo número el comportamiento típico de un conjunto de datos: el punto central alrededor del cual se agrupa la mayor parte de los valores. Son tres: la media, la mediana y la moda.

Medida	Responde a la pregunta	Se puede usar con
Media	¿Cuál es el valor promedio?	Variables cuantitativas
Mediana	¿Cuál es el valor central?	Cuantitativas y cualitativas ordinales
Moda	¿Cuál es el valor más frecuente?	Cualquier tipo de variable

Para las variables categóricas el resumen habitual son las frecuencias (sección 3); estas tres medidas se aplican sobre todo a datos numéricos.

4.1 Media aritmética (promedio)

La media es la suma de todos los valores dividida entre el número de datos.

```
\bar{x} = \frac{\sum x}{n}
```

Donde x son los valores del conjunto y n es el número total de datos.

Ejemplo. Si la suma de las edades de 20 estudiantes es 377: x̄ = 377 / 20 = **18.85 años**.

Media con tabla de frecuencias. Cuando los datos están agrupados, cada valor se pondera por su frecuencia:

```
\bar{x} = \frac{\sum (f_i \cdot x_i)}{\sum f_i}
```

Procedimiento: (1) multiplicar cada valor xi por su frecuencia fi; (2) sumar los resultados; (3) dividir entre el total de datos. Si los datos están en intervalos, xi es la marca de clase.

4.2 Valores atípicos (outliers)

Un **valor atípico** es un dato extremadamente grande o pequeño que se aleja del resto. Distorsiona la media, porque esta usa todos los valores.

Ejemplo. Diez estudiantes tienen edades entre 15 y 23 años: 16, 17, 17, 18, 18, 19, 19, 20, 21, 23. Si se añaden dos personas de 64 y 65 años:

Medida	Sin atípicos (n = 10)	Con atípicos (n = 12)
Media	18.80	26.42
Mediana	18.5	19

La media sube más de 7 años aunque la mayoría del grupo sigue siendo joven; la mediana apenas cambia. Por eso se dice que la mediana es **robusta** frente a valores extremos y la media no.

4.3 Mediana

La mediana es el valor que ocupa el centro de un conjunto de datos **ordenados**: deja el 50 % de los datos por debajo y el 50 % por encima.

Pasos:

1. Ordenar los datos de menor a mayor.
2. Identificar el valor central según n:
   - **n impar:** la mediana es el dato en la posición (n + 1) / 2.
   - **n par:** se toman los datos en las posiciones n / 2 y n / 2 + 1, y se promedian.

Ejemplos.

- Datos: 9, 3, 11, 5, 7 → ordenados: 3, 5, 7, 9, 11. Posición (5 + 1) / 2 = 3 → **Me = 7**.
- Datos: 3, 5, 7, 9 → posiciones 2 y 3: Me = (5 + 7) / 2 = **6**.
- Si los dos valores centrales son 19 y 19: Me = (19 + 19) / 2 = **19**.

Mediana con tabla de frecuencias

Se usa la frecuencia acumulada (Fi):

1. Calcular n / 2. Con n = 20, n / 2 = 10; la mediana está en la posición 10.
2. Buscar el primer valor cuya Fi sea mayor o igual a n / 2. Ese valor contiene la mediana.

Si la Fi coincide **exactamente** con n / 2, los datos 10 y 11 caen en valores distintos, y la mediana es el promedio de ese valor y el siguiente.

Mediana para datos agrupados en intervalos

```
Me = L_i + \frac{\frac{n}{2} - F_{anterior}}{f_{mediana}} \cdot A
```

Símbolo	Significado
Li	Límite inferior del intervalo donde está la mediana (intervalo mediano)
n	Número total de datos
F anterior	Frecuencia acumulada del intervalo anterior al mediano
f mediana	Frecuencia (no acumulada) del intervalo mediano
A	Amplitud del intervalo (límite superior − límite inferior)

Ejemplo. Estaturas de n = 20 estudiantes.

1. n / 2 = 10.
2. El intervalo mediano es el primero cuya Fi es ⩾ 10: **1.65 – 1.70**.
3. Datos: Li = 1.65; F anterior = 8; f mediana = 3; A = 0.05.
4. Aplicar la fórmula:

```
Me = 1.65 + \frac{10 - 8}{3} \cdot 0.05 = 1.65 + 0.0333 = 1.6833
```

La mediana aproximada es **1.6833 m**. Es aproximada porque dentro del intervalo se supone que los datos están distribuidos de manera uniforme.

4.4 Moda

La moda es el valor que aparece con mayor frecuencia.

Ejemplo. En una tabla de edades, el valor 18 aparece 8 veces y ningún otro aparece tantas veces: **Mo = 18**.

- Un conjunto puede ser **unimodal** (una moda), **bimodal** (dos modas) o **multimodal** (varias). Si ningún valor se repite, no hay moda.

- **Datos agrupados:** la moda corresponde al intervalo de mayor frecuencia, llamado **clase modal**. Si varios intervalos comparten la frecuencia máxima, la distribución es multimodal.
- Para ubicar la moda dentro de la clase modal se puede usar:

```
Mo = L_i + \frac{d_1}{d_1 + d_2} \cdot A
```

Donde d1 es la frecuencia de la clase modal menos la de la clase anterior, y d2 es la frecuencia de la clase modal menos la de la clase siguiente.

4.5 Ejemplo integrado con tabla de frecuencias

Edades de otro grupo de 20 estudiantes:

Edad (xi)	fi	Fi	fi · xi
17	3	3	51
18	8	11	144
19	5	16	95
20	4	20	80
Total	**20**		**370**

- **Media:** 370 / 20 = **18.5** años.
- **Mediana:** n / 2 = 10; el primer Fi ⩾ 10 es 11 (edad 18) → **Me = 18**.
- **Moda:** la mayor fi es 8 → **Mo = 18**.

La media (18.5) es algo mayor que la mediana y la moda (18): hay una cola ligera hacia las edades altas, es decir, un leve sesgo a la derecha.

4.6 Sesgo y relación entre media, mediana y moda

Cuando los valores extremos afectan la distribución, esta se vuelve **asimétrica** (sesgada). Los extremos "jalan" la media hacia su lado más que a la mediana y la moda, y eso permite identificar la forma de la distribución.

Forma	Dónde están los extremos	Relación típica
Simétrica	Repartidos por igual	media = mediana = moda

Forma	Dónde están los extremos	Relación típica
Sesgo a la derecha (positivo)	Valores altos (cola hacia la derecha)	media > mediana > moda
Sesgo a la izquierda (negativo)	Valores bajos (cola hacia la izquierda)	media < mediana < moda

Estas relaciones se cumplen en distribuciones unimodales típicas; en casos atípicos pueden fallar.

Qué medida elegir:

- Distribución simétrica y sin atípicos → **media**.
- Distribución sesgada o con atípicos → **mediana**.
- Variables categóricas (nominales) → **moda**.

```
df["edad"].mean()     # media
df["edad"].median()   # mediana
df["edad"].mode()     # moda (devuelve una Serie: puede haber varias)
```

5. Medidas de dispersión

La media no cuenta toda la historia: dos grupos pueden tener la misma media y una variabilidad muy distinta. Las medidas de dispersión cuantifican qué tan concentrados o esparcidos están los datos.

Grupo	Datos	Media	Rango	Desv. estándar (poblacional)	¿Qué pasa?
A	68, 70, 72, 69, 71	70	4	1.41	Todos cerca de la media
B	40, 90, 55, 95, 70	70	55	20.74	Misma media, datos muy dispersos

Las medidas de dispersión revelan la variabilidad que la media oculta. Las cuatro principales son:

Medida	Fórmula	Qué mide	Unidades	¿Robusta ante atípicos?
Rango	Máx − Mín	Amplitud total	Originales	No
Varianza	$\Sigma(x_i - \bar{x})^2 / N$	Dispersión al cuadrado	Cuadradas	No

Medida	Fórmula	Qué mide	Unidades	¿Robusta ante atípicos?
Desviación estándar	√varianza	Dispersión típica respecto a la media	Originales	No
IQR	Q3 − Q1	Dispersión del 50 % central	Originales	Sí

5.1 Rango

Es la diferencia entre el valor máximo y el mínimo: **R = Máx − Mín**.

Ejemplo. Edades: 18, 22, 25, 30, 35 → R = 35 − 18 = **17 años**.

```
rango = df["edad"].max() - df["edad"].min()
```

- **Ventaja:** es muy fácil de calcular y da la idea más básica de la dispersión.
- **Desventaja:** un solo valor extremo lo distorsiona por completo (es sensible a los atípicos), así que debe interpretarse con cuidado.

5.2 Varianza (σ^2 o s^2)

La varianza es el promedio de las desviaciones al cuadrado respecto a la media.

```
\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{N} \qquad s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}
```

La primera fórmula es la varianza **poblacional** (se tienen todos los datos de la población, N). La segunda es la **muestral** (solo se tiene una muestra de tamaño n) y divide entre n − 1; es la más usada en la práctica.

Pasos: (1) calcular la media; (2) restar la media a cada dato; (3) elevar al cuadrado cada desviación; (4) promediar esos cuadrados.

Ejemplo. Tiempos de entrega en días: 2, 3, 7, 4, 4.

Paso	Operación	Resultado
1	Media: (2 + 3 + 7 + 4 + 4) / 5	4
2	Desviaciones (xi − 4)	−2, −1, 3, 0, 0
3	Cuadrados	4, 1, 9, 0, 0 (suma = 14)
4a	Varianza poblacional: 14 / 5	**2.8 días²**

Paso	Operación	Resultado
4b	Varianza muestral: 14 / (5 − 1)	**3.5 días²**

La varianza queda en unidades al cuadrado (días²), lo que dificulta interpretarla directamente.

```
var_muestral = df["tiempo"].var()           # divide entre n - 1 (ddof=1,
valor por defecto)
var_poblacional = df["tiempo"].var(ddof=0)  # divide entre n
```

- `ddof=0`: poblacional (se usan todos los datos de la población).
- `ddof=1`: muestral (solo se tiene una muestra). Es el valor por defecto en pandas y el más común en la práctica.

5.3 Desviación estándar (σ o s)

Es la raíz cuadrada de la varianza: **σ = √varianza**. Al volver a las unidades originales de los datos, es mucho más fácil de interpretar.

Ejemplo. Con la varianza poblacional 2.8: σ = √2.8 ≈ **1.67 días**. Con la muestral 3.5: s = √3.5 ≈ 1.87 días. Interpretación: los tiempos se alejan típicamente unos 1.7 días de la media.

```
std_muestral = df["tiempo"].std()           # ddof=1 por defecto
std_poblacional = df["tiempo"].std(ddof=0)
```

Consejo: usa la desviación estándar para reportar resultados y la varianza para cálculos intermedios.

5.4 Cuartiles

Los cuartiles son puntos que dividen los datos ordenados en cuatro partes iguales (25 % cada una).

Cuartil	Significado	Percentil
Q0	Mínimo	0 %
Q1	Primer cuartil	25 %
Q2	Mediana	50 %
Q3	Tercer cuartil	75 %
Q4	Máximo	100 %

Cálculo manual (método de las mitades). Se ordenan los datos, se calcula la mediana (Q2), y luego Q1 es la mediana de la mitad inferior y Q3 la mediana de la mitad superior.

Ejemplo. Datos ordenados: 2, 4, 6, 8, 10, 12, 14, 16 (n = 8).

- Q2 = (8 + 10) / 2 = **9**.
- Mitad inferior: 2, 4, 6, 8 → Q1 = (4 + 6) / 2 = **5**.
- Mitad superior: 10, 12, 14, 16 → Q3 = (12 + 14) / 2 = **13**.

Existen varios métodos para calcular cuartiles y pueden dar resultados ligeramente distintos. Con los mismos datos:

Método	Q1	Q2	Q3	IQR
Mediana de cada mitad	5	9	13	8
Posición k(n + 1) / 4 con interpolación	4.5	9	13.5	9
pandas `quantile` (interpolación lineal)	5.5	9	12.5	7

No hay un método "incorrecto": lo importante es usar el mismo de forma consistente y saber cuál estás usando. En estos apuntes, los cálculos manuales usan el método de las mitades.

```
Q1 = df["columna"].quantile(0.25)
Q2 = df["columna"].quantile(0.50)   # mediana
Q3 = df["columna"].quantile(0.75)
```

5.5 Rango intercuartil (IQR)

El IQR es la diferencia entre Q3 y Q1 y mide la dispersión del **50 % central** de los datos: **IQR = Q3 − Q1**.

Ejemplo. Con Q1 = 5 y Q3 = 13: IQR = 13 − 5 = **8**. La amplitud del 50 % central de los datos (del percentil 25 al 75) es de 8 unidades.

Ventaja clave: es robusto, porque los valores extremos no afectan a Q1 ni a Q3.

Conjunto	Datos	Rango	IQR
Sin atípico	10, 20, 30, 40, 50, 60, 70	60	40
Con atípico	10, 20, 30, 40, 50, 60, 500	490	40 (igual)

El rango se dispara de 60 a 490, pero el IQR no cambia.

5.6 El 50 % central

El 50 % central son **todos los datos que están entre Q1 y Q3**, incluidos los que quedan por encima y por debajo de la mediana.

```
Datos ordenados de menor a mayor:

  [ Mín ]--[ 25 % bajo ]--Q1--[ 50 % central ]--Q3--[ 25 % alto ]--[ Máx ]
```

No incluye el 25 % de datos más bajos (debajo de Q1) ni el 25 % más alto (encima de Q3).

Analogía del salón. Con 20 estudiantes ordenados por estatura, Q1 está aproximadamente en el estudiante n.º 6 y Q3 en el n.º 15. El 50 % central son los estudiantes del 6 al 15, unos 10 en total.

Diferencia con "el 50 % de los datos". "El 50 % de los datos" podría ser cualquier mitad (la más baja, la más alta). El 50 % central es específicamente la mitad del medio, la que queda entre los percentiles 25 y 75 e ignora los extremos.

5.7 Cómo interpretar el IQR

Ejemplo con estaturas. Q1 = 1.58 m, Q3 = 1.76 m → IQR = 0.18 m (18 cm). La mitad central de los estudiantes tiene estaturas que varían dentro de un rango de 18 cm. Si el rango total es 1.95 − 1.50 = 45 cm, los extremos son los que ensanchan el rango: la mayoría está en un intervalo más compacto.

Al analizar Q1, Q2, Q3 e IQR conviene responder tres preguntas:

1. **¿Qué tan ancho es el 50 % central?** (IQR). IQR pequeño: datos centrales concentrados, poca variabilidad. IQR grande: datos centrales dispersos, alta variabilidad.
2. **¿Dónde está ubicado el 50 % central?** (Q1 y Q3). Si ambos son bajos, la mayoría de los datos son bajos; si ambos son altos, la mayoría son altos; si Q1 es bajo y Q3 es alto, los datos están muy dispersos.
3. **¿Cómo está ubicada la mediana dentro del 50 % central?** (sesgo), según la tabla siguiente.

Mediana ubicada…	Parte más larga de la caja	Sesgo	Relación media–mediana
Cerca de Q1 (abajo)	Hacia Q3 (arriba)	A la derecha	Media > mediana
Cerca de Q3 (arriba)	Hacia Q1 (abajo)	A la izquierda	Media < mediana
En el centro	Ambos lados iguales	Simétrico	Media ≈ mediana

Regla mnemotécnica: derecha = hacia arriba = los valores altos jalan la media.

5.8 Detección de outliers: regla del 1.5 × IQR

$$L_{inferior} = Q1 - 1.5 \cdot IQR \qquad L_{superior} = Q3 + 1.5 \cdot IQR$$

Cualquier valor fuera de estos límites se considera atípico.

Ejemplo con notas. Q1 = 277.5, Q3 = 387.5, IQR = 110.

- Límite inferior = 277.5 − 1.5 × 110 = 277.5 − 165 = **112.5**.
- Límite superior = 387.5 + 1.5 × 110 = 387.5 + 165 = **552.5**.
- Son atípicos los valores menores que 112.5 o mayores que 552.5.

```
Q1 = df["nota"].quantile(0.25)
Q3 = df["nota"].quantile(0.75)
IQR = Q3 - Q1

lim_inf = Q1 - 1.5 * IQR
lim_sup = Q3 + 1.5 * IQR

outliers = df[(df["nota"] < lim_inf) | (df["nota"] > lim_sup)]
```

Que un dato sea atípico no significa que sea un error: primero se investiga su origen y solo después se decide si se conserva, se corrige o se elimina.

5.9 Ejemplo integrador

Tiempos de respuesta en minutos (n = 10): 3, 5, 7, 8, 9, 10, 12, 14, 15, 45.

Medida	Valor	Interpretación
Media	12.8 min	Inflada por el dato de 45 min
Mediana	9.5 min	Representa mejor el tiempo típico

Medida	Valor	Interpretación
Rango	42 min	Inflado por el atípico de 45 min
Varianza muestral	142.18 min^2	Unidades al cuadrado, difícil de interpretar
Desviación estándar muestral	11.92 min	También inflada por el atípico
Q1 y Q3 (método de las mitades)	7 y 14 min	El 50 % central está entre 7 y 14 min
IQR	7 min	El 50 % central es estable
Límites 1.5 × IQR	−3.5 y 24.5 min	El 45 queda fuera: es un atípico

Conclusión: el atípico engaña al rango, a la media y a la desviación estándar. El IQR y la mediana muestran que la mayoría de las llamadas tienen tiempos similares.

6. Visualización de datos

El gráfico correcto depende del tipo de variable: barras y torta para categorías; histograma, ojiva y diagrama de caja para variables cuantitativas; Pareto para priorizar causas.

Gráfico	Tipo de variable	Para qué sirve
Barras	Categórica	Comparar frecuencias entre categorías
Torta (pie)	Categórica, 2 a 5 categorías	Mostrar la proporción de cada parte en un total
Histograma	Cuantitativa continua (o discreta con muchos valores)	Ver la forma de la distribución
Ojiva	Cuantitativa	Estimar percentiles a partir de la frecuencia acumulada
Diagrama de Pareto	Categórica (causas, defectos)	Priorizar los pocos factores que más pesan
Diagrama de caja (boxplot)	Cuantitativa	Resumir los cinco estadísticos y detectar atípicos

6.1 Gráfico de barras

- **Uso:** variables categóricas.
- **Característica:** las barras van **separadas**, porque las categorías son valores distintos y no continuos.
- **Ejes:** categorías en el eje X, frecuencias en el eje Y.
- **Interpretación:** permite comparar qué categoría domina.

6.2 Gráfico de torta (pie chart)

- **Uso:** solo con 2 a 5 categorías, cuando las partes forman un total del 100 %.
- **Limitación:** funciona mal con muchas categorías, porque al ojo humano le cuesta comparar ángulos y áreas.
- **Interpretación:** el sector más grande es la categoría que domina.

6.3 Histograma

- **Uso:** variables cuantitativas continuas (o discretas con muchos valores).
- **Característica:** las barras son **contiguas** (se tocan), porque los intervalos son continuos. Esta es la diferencia visual con el gráfico de barras.
- **Muestra:** la forma de la distribución (simétrica, sesgada, bimodal).
- **Interpretación:** dónde se concentran los datos y si hay valores atípicos visibles.

6.4 Ojiva (frecuencia acumulada)

- **Uso:** estimar percentiles (Q1, mediana, Q3).
- **Característica:** es una línea que **nunca decrece**, porque acumula frecuencias. Se construye con la frecuencia acumulada (Fi o Hi) frente al límite superior de cada intervalo.
- **Cómo se lee:** se ubica un porcentaje en el eje Y, se traza una línea horizontal hasta la curva y se baja hasta el eje X.
  - 25 % en Y → X es Q1.
  - 50 % en Y → X es la mediana.
  - 75 % en Y → X es Q3.

6.5 Diagrama de Pareto

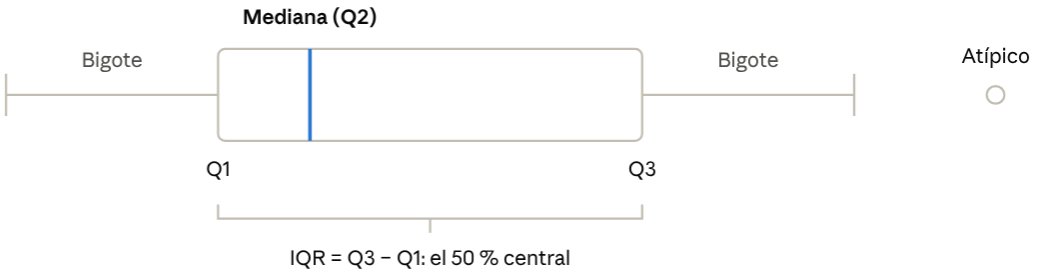
- **Uso:** aplicar el principio 80/20 (pocos vitales, muchos triviales): aproximadamente el 80 % de los efectos proviene del 20 % de las causas. Es una regla empírica, no una ley exacta.

- **Característica:** barras en orden **descendente** más una línea de porcentaje acumulado (con su propio eje a la derecha).
- **Interpretación:** las primeras barras, hasta donde la línea cruza el 80 %, son los "pocos vitales" que conviene priorizar.

6.6 Diagrama de caja y bigotes (boxplot)

Resume cinco estadísticos (mínimo, Q1, mediana, Q3, máximo) y marca los atípicos.

Mediana cerca de Q1 y atípico a la derecha: sesgo a la derecha



anatomía del boxplot · caja, mediana, bigotes y atípico

La caja va de Q1 a Q3 (el 50 % central) y la línea marca la mediana. Los bigotes llegan al dato más extremo que aún está dentro de 1.5 × IQR; los puntos fuera de ellos son atípicos. Aquí la mediana queda cerca de Q1 y el bigote superior es más largo: sesgo a la derecha.

Anatomía:

- **Caja:** va de Q1 a Q3, es decir, el IQR (50 % central).
- **Línea dentro de la caja:** la mediana (Q2).
- **Bigotes:** se extienden desde la caja hasta el dato más extremo que todavía está dentro de 1.5 × IQR (los datos "no atípicos").
- **Puntos fuera de los bigotes:** valores atípicos.

Interpretación del sesgo:

- Mediana cerca de Q1 (parte baja de la caja): **sesgo a la derecha** (cola hacia arriba).
- Mediana cerca de Q3 (parte alta de la caja): **sesgo a la izquierda** (cola hacia abajo).
- Mediana centrada: distribución **simétrica**.

6.7 Cómo graficar con pandas

```
df["Mano"].value_counts().plot(kind="bar")       # barras (categórica)
df["Mano"].value_counts().plot(kind="pie")       # torta (pocas categorías)
df["Horas/día"].plot(kind="hist", bins=6)        # histograma
df.boxplot(column="Horas/día")                   # diagrama de caja
```

7. Tratamiento de datos personales en Colombia (Ley 1581 de 2012)

En Colombia, el tratamiento de datos personales está regulado por la **Ley 1581 de 2012**, que establece principios, derechos y obligaciones para las organizaciones que recolectan o procesan información personal. Es especialmente relevante en contextos como las copropiedades o la propiedad horizontal, donde se manejan datos de residentes, visitantes y empleados.

Este bloque es material de estudio, no asesoría jurídica.

7.1 ¿Qué es un dato personal?

Un **dato personal** es cualquier información que permita identificar o hacer identificable a una persona natural. Ejemplos: nombre, dirección, número de teléfono, fotografías, videos y huellas biométricas.

7.2 Clasificación de los datos personales

Categoría	Definición	Ejemplos	¿Requiere autorización?
Público	Accesible para cualquier persona	Estado civil, profesión u oficio, calidad de comerciante o servidor público, registros públicos, sentencias judiciales ejecutoriadas no reservadas	No
Semiprivado	No es completamente público; interesa al titular y a un grupo o sector específico	Correo electrónico, dirección de residencia, información financiera o crediticia	Sí

Categoría	Definición	Ejemplos	¿Requiere autorización?
Privado	Solo interesa al titular; acceso restringido	Nivel educativo, documentos privados	Sí
Sensible	Afecta la intimidad del titular o puede generar discriminación	Datos biométricos, salud (historia clínica), orientación sexual, ideología política, origen racial o étnico, convicciones religiosas	Sí, con consentimiento **explícito** y protección especial

La Ley 1581 define los datos sensibles; la distinción entre público, semiprivado y privado se apoya en el régimen de *habeas data* (Ley 1266 de 2008). La clasificación de un dato puede depender del contexto en que se use: ante la duda, se solicita autorización.

7.3 Principios del tratamiento

Principio	Idea central
Legalidad	El tratamiento se rige por la ley y sus normas reglamentarias
Finalidad	Debe tener un propósito legítimo, informado al titular
Libertad	Requiere el consentimiento previo, expreso e informado del titular
Veracidad o calidad	La información debe ser veraz, completa, exacta y actualizada
Transparencia	El titular puede saber en cualquier momento qué datos suyos se tratan
Acceso y circulación restringida	Solo acceden las personas autorizadas
Seguridad	Se adoptan medidas técnicas y administrativas para proteger los datos
Confidencialidad	Quien interviene en el tratamiento debe guardar reserva

7.4 Datos biométricos y videovigilancia

Los sistemas de videovigilancia implican tratamiento de datos personales, porque las imágenes permiten identificar personas. Por eso las organizaciones deben:

- Informar a los usuarios.
- Colocar avisos de privacidad.
- Incluir el tratamiento en la política de datos.

La autoridad que supervisa el cumplimiento es la **Superintendencia de Industria y Comercio (SIC)**.

7.5 Obligaciones de las organizaciones

Quienes recolectan datos deben:

1. Solicitar la autorización del titular.
2. Tener una política de tratamiento de datos.
3. Informar la finalidad del uso de los datos.
4. Garantizar los derechos del titular.
5. Proteger la información con medidas de seguridad adecuadas.

7.6 Derechos de los titulares

Los titulares de datos personales tienen derecho a:

- Conocer sus datos.
- Actualizar su información.
- Rectificar datos incorrectos.
- Solicitar la eliminación de sus datos.
- Retirar la autorización.
- Conocer el uso que se da a su información.
- Acudir ante la SIC para presentar quejas por incumplimientos.

7.7 Sanciones por incumplimiento

La SIC puede imponer multas de hasta **2.000 salarios mínimos mensuales legales vigentes (SMMLV)**, además de otras medidas, como la suspensión o el cierre de las actividades relacionadas con el tratamiento de datos.

8. Arquitecturas de almacenamiento y análisis de datos

Las organizaciones generan grandes cantidades de datos en sistemas como CRM, ERP, correos electrónicos, registros de interacción y archivos multimedia, y para obtener inteligencia de negocio esos datos deben centralizarse. Las tres arquitecturas principales son el Data Lake, el Data Warehouse y el Data Mart.

Los Data Marts salen del Data Warehouse; el Data Lake corre en paralelo



arquitectura de datos · fuentes, Data Lake, Data Warehouse y Data Marts

Las fuentes alimentan al Data Lake (datos en su formato original) y al Data Warehouse (datos limpios y estructurados), que se usan en paralelo; del Data Warehouse se derivan los Data Marts, uno por área.

8.1 Data Lake

Un **Data Lake** es un repositorio que almacena grandes cantidades de datos **en su formato original**. Puede contener datos estructurados, correos electrónicos, imágenes, audio, video y registros (*logs*).

- Enorme volumen de datos.
- Almacenamiento flexible.
- Requiere infraestructura especializada.
- Las consultas son complejas.

8.2 Data Warehouse

Un **Data Warehouse** almacena datos **estructurados y organizados** para facilitar el análisis.

- Datos limpios y organizados.
- Consultas rápidas.

- Optimizado para inteligencia de negocio.

8.3 Data Mart

Un **Data Mart** es una subsección del Data Warehouse enfocada en un área específica, por ejemplo marketing, ventas o finanzas.

- Mayor seguridad: cada área accede solo a los datos que necesita.
- Mayor eficiencia.
- Implementación más rápida.

8.4 Comparación

Sistema	Tipo de datos	Tamaño	Uso
Data Lake	Estructurados y no estructurados	Muy grande	Almacenamiento masivo
Data Warehouse	Estructurados	Grande	Análisis empresarial
Data Mart	Subconjunto de los datos del Warehouse	Pequeño	Análisis por departamento

8.5 Estrategia recomendada

Muchos analistas recomiendan usar un Data Lake y un Data Warehouse en paralelo, porque datos que hoy parecen irrelevantes pueden generar valor en el futuro. Sin embargo, los Data Lake pueden ser costosos, por lo que no todas las empresas los necesitan.

9. Caso de estudio: cómo YouTube recomienda videos

YouTube recomienda videos con un sistema de algoritmos que analiza el comportamiento del usuario; cada señal que usa es una variable que se mide, se resume con estadística y se emplea para decidir qué mostrar. Esta es una descripción simplificada: la plataforma no publica el detalle completo de su algoritmo.

Factor	Qué analiza
Historial de visualización	Videos similares a los que el usuario ya ha visto

Factor	Qué analiza
Tiempo de visualización (*watch time*)	Cuánto tiempo permanecen los usuarios viendo el video
Interacción	*Likes*, comentarios, veces compartido y suscripciones
Relevancia del contenido	Título, descripción, etiquetas y tema del canal
CTR (*click-through rate*)	Porcentaje de personas que hacen clic al ver la miniatura
Retención de audiencia	Qué porcentaje del video ve cada usuario

Dos de estos factores son proporciones, como las frecuencias relativas de la sección 3:

```
CTR = \frac{\text{clics}}{\text{impresiones}} \cdot 100 \qquad
\text{Retención} = \frac{\text{tiempo visto}}{\text{duración del video}}
\cdot 100
```

Para pensar: ¿qué medida de tendencia central usarías para resumir la retención de un video, la media o la mediana? ¿Qué pasaría si unos pocos usuarios lo ven completo varias veces?

10. Lectura complementaria: *The Thinking Game*

The Thinking Game ("El juego de pensar") es un documental dirigido por Greg Kohs sobre Google DeepMind, el laboratorio de inteligencia artificial liderado por Demis Hassabis, y su búsqueda de la inteligencia artificial general (AGI). Su logro más destacado es AlphaFold, que resolvió un problema de la biología con 50 años de antigüedad: predecir la forma de las proteínas.

El documental sigue al equipo durante varios años y se publicó de forma gratuita en YouTube a fines de 2025. Los datos de esta sección provienen de los apuntes de clase y del conocimiento general sobre DeepMind; conviene verificar fechas y cifras en fuentes oficiales.

10.1 Demis Hassabis

- **Infancia:** niño prodigio del ajedrez, llegó a ser uno de los mejores jugadores del mundo de su edad. En una entrevista de la BBC en 1986, con unos 9 años, describió el ajedrez como "un buen juego para pensar", origen del título del documental.
- **Videojuegos:** a los 17 años trabajó en Bullfrog Productions, donde diseñó la IA del videojuego *Theme Park* (simulación del comportamiento de las personas).

- **Formación:** estudió ciencias de la computación en Cambridge, fundó un estudio de videojuegos y después se doctoró en neurociencia cognitiva. Su idea de fondo: el cerebro humano es la única prueba de que la inteligencia general es posible.
- **DeepMind:** fundó el laboratorio en 2010. Google lo adquirió en 2014.
- **Objetivo:** construir una AGI para usarla como herramienta para resolver problemas científicos.

10.2 IA frente a AGI

Concepto	Significado
IA (inteligencia artificial)	Sistemas que realizan tareas específicas, como jugar ajedrez o reconocer imágenes
AGI (inteligencia artificial general)	Sistemas con razonamiento flexible, aprendizaje autónomo y capacidad de adaptarse a múltiples tareas, como un humano

El objetivo de DeepMind es construir AGI, no solo IA especializada.

10.3 Los juegos como campo de pruebas

DeepMind usó videojuegos y juegos de mesa para entrenar algoritmos **sin enseñarles las reglas, solo dándoles un objetivo**. Esta forma de entrenar se llama aprendizaje por refuerzo: el sistema prueba acciones y aprende de las recompensas que obtiene.

Fase	Hito	Qué demostró
Atari (DQN)	Aprendió a jugar *Breakout* viendo solo los píxeles	Descubrió por sí sola una estrategia no programada: abrir un túnel lateral
AlphaGo	2016: vence a Lee Sedol; 2017: vence a Ke Jie	El movimiento 37 contra Lee Sedol tenía una probabilidad estimada de 1 en 10.000 de ser jugado por un humano: mostró creatividad
AlphaZero	Evolución de AlphaGo	Aprendió desde cero jugando contra sí mismo, sin datos humanos
AlphaStar	*StarCraft II*	Planificó y decidió en tiempo real con información imperfecta ("niebla de guerra")

Idea central: los juegos fueron el entrenamiento de las herramientas (como aprender a pulir lentes) y AlphaFold fue el telescopio apuntado a un problema científico real.

10.4 AlphaFold

- **El problema:** una cadena de aminoácidos (1D) se pliega en una estructura 3D que determina su función. Conocer la forma permite entender enfermedades y diseñar fármacos. Llevaba unos 50 años sin resolverse.
- **CASP13 (2018):** DeepMind participa y gana, pero sin una precisión suficiente para la ciencia experimental.
- **CASP14 (2020):** AlphaFold 2 resuelve el problema con una precisión revolucionaria. El documental muestra cómo el equipo rediseñó el sistema durante el confinamiento por COVID-19.
- **Acceso abierto:** DeepMind liberó gratuitamente las estructuras de unos 200 millones de proteínas, casi todo el universo proteico conocido, como un "regalo para la humanidad".
- **Reconocimiento:** el Premio Nobel de Química 2024 fue compartido por Demis Hassabis y John Jumper (de DeepMind) y David Baker, por la predicción y el diseño computacional de proteínas.

10.5 Filosofía y ética

- **No al "muévete rápido y rompe cosas":** Hassabis rechaza la cultura de Silicon Valley; con sistemas que pueden superar la inteligencia humana, no se puede "romper cosas para arreglarlas después".
- **Adquisición por Google (2014):** DeepMind necesitaba una enorme capacidad de cómputo y negoció mantener su independencia cultural y ética, seguir en Londres y enfocarse en la ciencia y no solo en productos comerciales.
- **Líneas rojas:** el equipo ha expresado su rechazo al uso militar de su tecnología.
- **Paralelismo con el Proyecto Manhattan:** el documental plantea que la tecnología es neutral, pero su aplicación no.

10.6 Ideas de Hassabis

Idea	Contexto
La AGI será más grande que internet o el móvil; comparable a la llegada de la electricidad o del fuego	Impacto esperado de la AGI

Idea	Contexto
Resolver la inteligencia para usarla como herramienta para resolver todos los problemas científicos	Su motivación
AlphaFold es un regalo para la humanidad	Por qué liberó las estructuras de proteínas

11. Repaso final

Esta sección reúne lo que más conviene tener a mano antes de un examen: las fórmulas, las dudas que más se repiten y preguntas para comprobar qué tanto dominas el contenido.

11.1 Fórmulas clave

Concepto	Fórmula
Frecuencia relativa	hi = fi / n
Porcentaje	hi % = hi × 100
Frecuencia acumulada	Fi = f1 + f2 + … + fi
Marca de clase	xi = (límite inferior + límite superior) / 2
Media	$\bar{x} = \Sigma x / n$
Media con tabla de frecuencias	$\bar{x} = \Sigma(fi \cdot xi) / \Sigma fi$
Mediana (n impar)	Dato en la posición (n + 1) / 2
Mediana (n par)	Promedio de los datos en las posiciones n/2 y n/2 + 1
Mediana agrupada	Me = Li + [(n/2 − F anterior) / f mediana] · A
Moda agrupada	Mo = Li + [d1 / (d1 + d2)] · A
Rango	R = Máx − Mín
Varianza poblacional	$\sigma^2 = \Sigma(xi - \bar{x})^2 / N$
Varianza muestral	$s^2 = \Sigma(xi - \bar{x})^2 / (n - 1)$
Desviación estándar	σ = √varianza
Rango intercuartil	IQR = Q3 − Q1

Concepto	Fórmula
Límites de atípicos	Q1 − 1.5 · IQR y Q3 + 1.5 · IQR

11.2 Dudas frecuentes

Si IQR = 50, ¿qué concluyo? Que el 50 % central de los datos (de Q1 a Q3) abarca 50 unidades. No es la dispersión total, sino la de la mitad central, sin los extremos.

¿Qué datos pertenecen al 50 % central? Todos los que están entre Q1 y Q3. Con 20 datos ordenados, son aproximadamente los de la posición 6 a la 15, y hay datos por encima y por debajo de la mediana.

¿La mediana cerca de Q1 es sesgo derecho o izquierdo? Derecho. La caja se estira hacia arriba (de Q2 a Q3 es mayor), los valores altos jalan la media y se cumple media > mediana. Con la mediana cerca de Q3 pasa lo contrario: sesgo izquierdo y media < mediana.

Si agrego un atípico, ¿cambia el IQR? Muy poco o nada: Q1 y Q3 casi no se mueven. El rango, en cambio, se dispara. Por eso el IQR es robusto.

¿Qué significa IQR = 0? Que Q1 = Q3: el 50 % central tiene el mismo valor, lo que ocurre cuando hay muchos datos repetidos en el centro (por ejemplo, muchas personas con la misma edad).

¿"El 50 % central" no es lo mismo que "el 50 % de los datos"? No. El 50 % de los datos podría ser cualquier mitad (la más baja, la más alta). El 50 % central es la que queda entre los percentiles 25 y 75.

¿Por qué me da error `astype(int)` en una columna con valores faltantes? Los `NaN` no pueden convertirse a entero. Primero hay que rellenarlos (`fillna`) o eliminarlos (`dropna`).

¿Por qué mi DataFrame no cambia después de `df.sort_values(...)`? Porque el método devuelve una copia. Hay que reasignar: `df = df.sort_values(...)`.

11.3 Autoevaluación

Responde cada pregunta antes de mirar la respuesta.

N.º	Pregunta	Respuesta
1	¿Qué diferencia hay entre estadística descriptiva e inferencial?	La descriptiva resume y describe los datos observados; la inferencial saca conclusiones sobre una población a partir de una muestra

N.º	Pregunta	Respuesta
2	¿Cuándo se usa `on` y cuándo `left_on` / `right_on` en `pd.merge`?	`on` cuando la llave tiene el mismo nombre en ambas tablas; `left_on` / `right_on` cuando los nombres son distintos
3	¿Qué permite `ordered=True` en una variable categórica?	Declarar un orden lógico, comparar con `<` y `>` y ordenar según esa jerarquía
4	¿Por qué no tiene sentido una frecuencia acumulada en una variable nominal?	Porque sus categorías no tienen orden; acumular exige un orden
5	En un grupo de 20 datos, hi = 0.85 para "Derecha". ¿Cuántos datos son?	0.85 × 20 = 17
6	¿Cuál es la mediana de 3, 5, 7, 9?	(5 + 7) / 2 = 6
7	En una distribución con sesgo a la derecha, ¿qué es mayor, la media o la mediana?	La media (media > mediana > moda)
8	¿Qué es la clase modal?	El intervalo con la mayor frecuencia en datos agrupados
9	¿Qué divisor usa la varianza muestral y por qué es la más común?	n − 1; en la práctica casi siempre se trabaja con muestras
10	¿Qué mide el IQR y por qué es robusto?	La amplitud del 50 % central; depende solo de Q1 y Q3, no de los extremos
11	Si Q1 = 20 y Q3 = 40, ¿cuáles son los límites para detectar atípicos?	IQR = 20; inferior = 20 − 30 = −10; superior = 40 + 30 = 70
12	¿Cómo se distingue un histograma de un gráfico de barras?	En el histograma las barras se tocan (variable continua); en el de barras están separadas (categorías)
13	En un boxplot, la mediana está pegada a Q1. ¿Qué sesgo indica?	Sesgo a la derecha
14	¿Cuándo conviene `pd.qcut` en vez de `pd.cut`?	Cuando se quiere que cada intervalo tenga aproximadamente el mismo número de datos
15	¿Qué autoridad supervisa el tratamiento de datos personales en Colombia?	La Superintendencia de Industria y Comercio (SIC)

N.º	Pregunta	Respuesta
16	¿Qué diferencia hay entre un Data Warehouse y un Data Lake?	El Data Warehouse guarda datos estructurados y limpios para análisis; el Data Lake guarda datos en su formato original, estructurados o no